

**KOCAELİ ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ**

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

LİSANS TEZİ

**Müzikten Görsele: İnsan ve Yapay Zeka
Duygu Algısının Karşılaştırmalı
İncelemesi**

**Beril İsalır
Ecem Yalçın
Kocaeli Üniversitesi**

2026

MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

ARAŞTIRMA PROBLEMLERİ / BİTİRME PROJESİ

PROJE BAŞLIĞI

Müzikten Görsele: İnsan ve Yapay Zeka Duygu Algısının Karşılaştırmalı İncelemesi

**Ecem Yalçın
Beril İsalır**

Dr. Öğr. Üyesi Hikmetcan ÖZCAN

Danışman, Kocaeli Üniv.

Öğr. Gör. Dr. Onur GÖK

Jüri Üyesi, Kocaeli Üniv.

Arş. Gör. Kadir KESİMAL

Jüri Üyesi, Kocaeli Üniv.

ŞEKİLLER DİZİNİ

Şekil 5.1 Sistem Genel Mimarisi	23
Şekil 6.1 Örnek Mel-Spektrogram görselleri	34
Şekil 7.1 Uygulama Başlangıç ekranı	46
Şekil 7.2 Model Karşılaştırma Ekranı.....	47
Şekil 7.3 İnsan–Gemini karşılaştırma ekranı	48
Şekil 7.4 VA Duygu uzayında Gemini analizi ve insan duygusu farkı	48
Şekil 7.5'te İnsan – Seçili Model – Gemini Karşılaştırma ekranı.....	49
Şekil 7.6 Üçlü yaklaşımın grafiksel karşılaştırması	49
Şekil 7.7 Üçlü yaklaşımın sayısal karşılaştırması	50
Şekil 7.8 Demografik Analiz Ekranı	51
Şekil 7.9 Yaş Gruplarına Göre VA Dağılımları.....	51
Şekil 7.10 Cinsiyete göre VA bar chart	52
Şekil 7.11 Müzik dinlemeden önceki ve sonraki duygu durumu.....	52
Şekil 7.12 Soyut Görsel Oluşturma Ekranı.....	53
7.13 Barber:Adiogo for Strings parçasının oluşturulmuş soyut görseli.....	53

TABLolar DİZİNİ

Tablo 3.1 DEAM Veri Setinin Temel Özellikleri.....	17
Tablo 3.2 Anket Verisinin Genel Özellikleri.....	18
Tablo 3.3 Mel-Spektrogram üretimindeki parametreler	19
Tablo 5.1 Model Ağırlıklandırması	26
Tablo 5.2 Veritabanı Tasarımı	32
Tablo 7.1 Veri Seti Ayrımı.....	38
Tablo 7.2 Model Performans Sonuçları.....	40,41,42,43
Tablo 7.3 Ensemble Sonuçları	44

SİMGELER VE KISALTMALAR DİZİNİ

AI: Artificial Intelligence (Yapay Zeka)

API : Application Programming Interface

AST : Audio Spectrogram Transformer

BiLSTM: Bidirectional Long Short-Term Memory

CNN: Convolutional Neural Network (Evrişimsel Sinir Ağı)

CRNN: Convolutional Recurrent Neural Network

DEAM: Database for Emotional Analysis of Music

FFT: Fast Fourier Transform

GEMS : Geneva Emotional Music Scale

Hz: Hertz

JSON: JavaScript Object Notation

LLM : Large Language Model

MER : Music Emotion Recognition

MRS: Music Receptivity Scale

MSE: Mean Squared Error

RMSE : Root Mean Squared Error

VA : Valence–Arousal

V: Valence

A : Arousal

MÜZİKTEN GÖRSELE: İNSAN VE YAPAY ZEKA DUYGU ALGISININ KARŞILAŞTIRMALI İNCELEMESİ

ÖZET

Müzik, insanlar üzerinde farklı duygusal etkiler oluşturabilen güçlü bir iletişim aracıdır. Bu nedenle müziklerden duygu çıkarımı (Music Emotion Recognition - MER), son yıllarda yapay zeka ve müzik bilgi erişimi alanlarında önemli bir araştırma konusu haline gelmiştir. Bu çalışmada müzik duygu analizi problemi derin öğrenme, multimodal yapay zeka ve üretken yapay zeka teknolojileri kullanılarak incelenmiştir.

Çalışma kapsamında DEAM (Database for Emotional Analysis of Music) veri seti kullanılmış ve müziklerden Valence–Arousal değerlerinin tahmini amacıyla CNN, CRNN, Transformer ve hibrit mimariler geliştirilmiştir. Modellerin performanslarını artırmak amacıyla ağırlıklı ensemble yaklaşımı uygulanmıştır. Model performansları RMSE, MAE, Pearson Korelasyon Katsayısı ve Concordance Correlation Coefficient (CCC) metrikleri kullanılarak değerlendirilmiştir.

Yapay zeka modellerinin sonuçlarını insan algısıyla karşılaştırmak amacıyla çevrim içi anket çalışması gerçekleştirilmiştir. Katılımcılardan elde edilen duygu değerlendirmeleri normalize edilerek Valence–Arousal uzayına dönüştürülmüş ve insan duygu profilleri oluşturulmuştur. Ayrıca Google Gemini 2.5 Flash modeli kullanılarak aynı müzik parçaları üzerinde multimodal duygu analizleri gerçekleştirilmiş ve sonuçlar insan değerlendirmeleri ile karşılaştırılmıştır.

Çalışmanın özgün katkılarından biri olarak Emotion-to-Art Engine sistemi geliştirilmiştir. Bu sistem, kullanıcı anketlerinden elde edilen duygu dağılımlarını analiz ederek Emotion Profile, Art DNA, Color DNA ve Composition DNA yapıları oluşturmakta ve bu bilgileri kullanarak FLUX.1-schnell modeli aracılığıyla soyut sanat eserleri üretmektedir. Böylece müziklerden elde edilen duygu verileri yalnızca sayısal çıktılar olarak değil, aynı zamanda görsel sanat eserleri olarak da temsil edilebilmektedir.

Elde edilen sonuçlar, ensemble yaklaşımının tekil modellerden daha başarılı performans gösterdiğini ve yapay zeka modellerinin insan duygu algısına belirli ölçüde yaklaşabildiğini göstermektedir. Ayrıca multimodal yapay zeka sistemleri ve üretken sanat yaklaşımlarının müzik duygu analizi alanına yeni araştırma fırsatları sunduğu görülmüştür.

Anahtar Kelimeler: Müzik Duygu Analizi, Music Emotion Recognition, Derin Öğrenme, CNN, CRNN, Transformer, Ensemble Learning, Gemini, Üretken Yapay Zeka, Emotion-to-Art Engine, FLUX.

FROM MUSIC TO VISUALS: A COMPARITIVE STUDY OF HUMAN AND ARTIFICIAL INTELLIGENCE EMOTION PERCEPTION

ABSTRACT

Music is a powerful medium that can evoke a wide range of emotional responses in listeners. Therefore, Music Emotion Recognition (MER) has become an important research area in artificial intelligence and music information retrieval. In this study, the problem of music emotion recognition is investigated using deep learning, multimodal artificial intelligence, and generative AI technologies.

The DEAM (Database for Emotional Analysis of Music) dataset was employed, and several deep learning architectures including Convolutional Neural Networks (CNN), Convolutional Recurrent Neural Networks (CRNN), Transformer-based models, and hybrid architectures were developed to predict Valence and Arousal values from music signals. In addition, a weighted ensemble approach was implemented to improve prediction performance. Model performance was evaluated using RMSE, MAE, Pearson Correlation Coefficient, and Concordance Correlation Coefficient (CCC) metrics.

To compare artificial intelligence predictions with human perception, an online survey study was conducted. Participants' emotional evaluations were normalized and transformed into the Valence–Arousal space to generate human emotion profiles. Furthermore, multimodal emotion analysis was performed using Google Gemini 2.5 Flash, and the obtained results were compared with human evaluations.

As one of the original contributions of this thesis, an Emotion-to-Art Engine was developed. The system analyzes emotional distributions obtained from survey responses and generates Emotion Profiles, Art DNA, Color DNA, and Composition DNA structures. These outputs are then utilized by the FLUX.1-schnell generative model to create abstract artworks representing the emotional characteristics of music. Consequently, emotional information extracted from music is represented not only as numerical predictions but also as visual artistic outputs.

The experimental results demonstrate that ensemble learning approaches outperform individual models and that artificial intelligence systems can approximate human emotional perception to a certain extent. Moreover, the findings indicate that multimodal AI systems and generative art frameworks provide promising opportunities for future research in music emotion recognition.

Keywords: Music Emotion Recognition, Deep Learning, CNN, CRNN, Transformer, Ensemble Learning, Gemini, Generative Artificial Intelligence, Emotion-to-Art Engine, FLUX.

1. GİRİŞ

Problem Tanımı

Müzik, insan yaşamında yalnızca estetik bir unsur değil, aynı zamanda bireylerin duygusal durumlarını etkileyen güçlü bir iletişim ve ifade aracıdır. İnsanlar dinledikleri müzikler aracılığıyla mutluluk, huzur, heyecan, nostalji, melankoli ve hüzn gibi çok çeşitli duygular yaşamaktadır. Bu nedenle müziğin insanlar üzerinde oluşturduğu duygusal etkilerin anlaşılması; psikoloji, nörobilim, müzikoloji ve bilgisayar bilimi gibi farklı disiplinlerin ortak ilgi alanı haline gelmiştir.

Dijital müzik platformlarının yaygınlaşmasıyla birlikte milyonlarca müzik parçasının otomatik olarak analiz edilmesi ihtiyacı ortaya çıkmıştır. Özellikle müzik öneri sistemleri, kişiselleştirilmiş çalma listeleri, terapi uygulamaları, eğitim teknolojileri ve insan-bilgisayar etkileşimi alanlarında müziğin duygusal içeriğinin doğru biçimde belirlenmesi önemli bir gereksinim haline gelmiştir. Bu ihtiyaç doğrultusunda gelişen Müzikten Duygu Tanıma (Music Emotion Recognition – MER) alanı, müzik parçalarının insanlar üzerinde oluşturduğu duygusal etkileri yapay zeka yöntemleri yardımıyla tahmin etmeyi amaçlamaktadır.

Ancak müzikten duygu çıkarımı problemi, yalnızca ses sinyalinin analiz edilmesinden ibaret değildir. Çünkü müzik algısı büyük ölçüde öznel bir yapıya sahiptir. Aynı müzik parçası farklı bireylerde farklı duygusal tepkiler oluşturabilmektedir. Bir kişinin huzurlu olarak değerlendirdiği bir eser, başka bir kişi tarafından melankolik veya nostaljik olarak algılanabilmektedir. Bu durum, müzik duygu analizinin yalnızca akustik özellikler üzerinden açıklanamayacağını ve bireysel deneyimlerin, kültürel geçmişin ve kişisel duygu durumunun da önemli rol oynadığını göstermektedir.

Son yıllarda derin öğrenme yöntemlerinin gelişmesiyle birlikte Evrişimsel Sinir Ağları (CNN), Evrişimsel Tekrarlayan Sinir Ağları (CRNN) ve Transformer tabanlı modeller müzik duygu analizinde yaygın olarak kullanılmaya başlanmıştır. Bununla birlikte multimodal üretken yapay zeka sistemleri de ses verisini doğrudan yorumlayabilme yetenekleri sayesinde bu alanda yeni araştırma fırsatları sunmaktadır. Özellikle Google Gemini gibi büyük ölçekli multimodal modeller, ses içeriğini analiz ederek müziğin oluşturduğu duygusal etkiler hakkında değerlendirmelerde bulunabilmektedir.

Literatürde insan algısı, derin öğrenme modelleri ve multimodal yapay zeka sistemlerini aynı çalışma kapsamında karşılaştırmalı olarak inceleyen araştırmalar sınırlı sayıdadır. Ayrıca mevcut çalışmaların büyük bölümü duygu tahmini üzerinde

yoğunlaşırken, elde edilen duygu bilgilerinin görsel sanat üretimine dönüştürülmesi ve yaratıcı yapay zeka sistemleriyle bütünleştirilmesi yeterince ele alınmamıştır.

Bu çalışma, söz konusu eksiklikleri gidermeyi amaçlayan bütünsel bir yaklaşım sunmaktadır. İnsan katılımcılardan elde edilen duygu verileri, derin öğrenme tabanlı müzik duygu analizi modelleri ve multimodal yapay zeka sistemleri ortak bir çerçevede değerlendirilmiş; elde edilen duygu profilleri üretken yapay zeka modelleri kullanılarak görsel sanat eserlerine dönüştürülmüştür. Böylece müzik, duygu analizi ve üretken yapay zeka alanlarını bir araya getiren disiplinlerarası bir sistem geliştirilmiştir.

Çalışmanın Amacı

Bu çalışmanın temel amacı, müzik parçalarının insanlar üzerinde oluşturduğu duygusal etkileri analiz etmek, yapay zeka modellerinin bu duygusal etkileri ne ölçüde tahmin edebildiğini incelemek ve elde edilen sonuçları karşılaştırmalı olarak değerlendirmektir.

Bu amaç doğrultusunda öncelikle DEAM veri seti kullanılarak farklı derin öğrenme modelleri eğitilmiş ve müzik parçalarının Valence–Arousal (VA) değerleri tahmin edilmiştir. Daha sonra insan katılımcılardan elde edilen anket verileri kullanılarak müziklerin insanlar üzerinde oluşturduğu duygusal etkiler sayısal hale getirilmiş ve yapay zeka tahminleriyle karşılaştırılmıştır.

Çalışmanın bir diğer amacı, Google Gemini 2.5 Flash modeli gibi yapay zeka sistemlerinin müzik duygu analizindeki performansını incelemek ve insan algısına olan yakınlığını değerlendirmektir.

Bunlara ek olarak çalışma kapsamında geliştirilen Emotion-to-Art Engine sistemi ile müziklerden elde edilen duygu profilleri kullanılarak özgün sanat temsilleri oluşturulmuş ve FLUX.1-schnell modeli aracılığıyla soyut sanat görselleri üretilmiştir. Böylece müzik duygu analizinden elde edilen sonuçlar yalnızca sayısal değerlendirmelerle sınırlı kalmamış, yaratıcı yapay zeka uygulamalarına da dönüştürülmüştür.

Çalışmanın Kapsamı

Bu çalışma kapsamında müzik duygu analizi problemi insan algısı ve yapay zeka perspektiflerinden ele alınmıştır.

Araştırmada;

- DEAM veri seti kullanılmıştır.
- CNN, CRNN, Transformer ve Ensemble tabanlı derin öğrenme modelleri geliştirilmiştir.

- İnsan katılımcılardan elde edilen anket verileri analiz edilmiştir.
- Google Gemini 2.5 Flash modeli kullanılarak ses tabanlı duygu değerlendirmeleri gerçekleştirilmiştir.
- Streamlit tabanlı etkileşimli bir analiz platformu geliştirilmiştir.
- İnsan, yapay zeka modelleri ve Gemini çıktıları karşılaştırılmıştır.
- Emotion-to-Art Engine mimarisi geliştirilmiştir.
- FLUX.1-schnell modeli kullanılarak duygu temelli soyut sanat görselleri üretilmiştir.
- Analiz geçmişlerinin saklanabilmesi amacıyla DynamoDB tabanlı bir kayıt sistemi kullanılmıştır.

Bu kapsamda geliştirilen sistem, müzik duygu analizi, insan-yapay zeka karşılaştırması ve üretken sanat üretimi süreçlerini tek platform altında birleştiren bütünlük bir yapı sunmaktadır.

2. LİTERATÜR ÖZETİ

Müzik duygu analizi (Music Emotion Recognition – MER), müzik parçalarının insanlar üzerinde oluşturduğu duygusal etkilerin otomatik yöntemlerle belirlenmesini amaçlayan disiplinlerarası bir araştırma alanıdır. Son yıllarda dijital müzik platformlarının yaygınlaşması ve yapay zeka teknolojilerindeki gelişmeler sayesinde bu alana olan ilgi önemli ölçüde artmıştır.

Müzikte duygu modelleme konusunda yapılan çalışmalar incelendiğinde iki temel yaklaşım öne çıkmaktadır. Bunlardan ilki mutluluk, üzüntü, öfke ve korku gibi önceden tanımlanmış duygu kategorilerini kullanan ayrık (discrete) modellerdir. İkinci yaklaşım ise duyguları sürekli bir uzayda temsil eden boyutsal (dimensional) modellerdir. Zentner, Grandjean ve Scherer (2008) tarafından geliştirilen Geneva Emotional Music Scale (GEMS), müziğe özgü duyguları tanımlayarak geleneksel duygu sınıflandırmalarının ötesine geçen önemli çalışmalardan biridir. GEMS modeli; huzur, hayranlık, nostalji ve güçlenme gibi müziğe özgü duygusal deneyimleri tanımlayarak müzik psikolojisi alanında önemli katkılar sunmuştur.

Boyutsal duygu modelleri içerisinde en yaygın kullanılan yaklaşım Russell (1980) tarafından önerilen Valence–Arousal (VA) modelidir. Bu modelde valence boyutu duygunun olumlu veya olumsuz olma derecesini, arousal boyutu ise duygunun enerji seviyesini temsil etmektedir. Eerola ve Vuoskoski (2011), müzik duygu analizinde kullanılan ayrık ve boyutsal duygu modellerini karşılaştırmış ve özellikle müzik uyarılarının değerlendirilmesinde Valence–Arousal modelinin daha tutarlı ve güvenilir sonuçlar verdiğini göstermiştir. Bu nedenle günümüzde müzik duygu analizi çalışmalarının büyük bölümü VA modeli üzerine kurulmaktadır.

Müzik duygu analizi alanında kullanılan veri setleri arasında DEAM (Database for Emotional Analysis of Music) veri seti önemli bir yere sahiptir. Aljanaki, Yang ve Soleymani (2017) tarafından geliştirilen bu veri seti, müzik parçaları için sürekli Valence ve Arousal etiketleri sunması nedeniyle derin öğrenme tabanlı çalışmaların büyük bölümünde kullanılmaktadır. Veri seti, farklı müzik türlerinden oluşan 1800'den fazla parçayı içermekte ve her parça için çok sayıda katılımcının duygu değerlendirmelerini barındırmaktadır.

Derin öğrenme yöntemlerinin gelişmesiyle birlikte Evrişimsel Sinir Ağları (Convolutional Neural Networks – CNN) müzik duygu analizinde yaygın olarak kullanılmaya başlanmıştır. CNN modelleri, mel-spektrogram temsilleri üzerinden müzik sinyalindeki akustik örüntüleri öğrenebilmekte ve duygu tahmini gerçekleştirebilmektedir. Choi ve arkadaşları (2017), derin CNN mimarilerinin müzik bilgi erişimi problemlerinde etkili sonuçlar ürettiğini göstermiştir. Benzer şekilde Kim ve arkadaşları (2019), CNN tabanlı modellerin müzik duygu analizi problemlerinde geleneksel makine öğrenmesi yöntemlerine göre daha başarılı performans sergilediğini rapor etmiştir.

CNN mimarilerinin zamansal bağımlılıkları modelleme konusunda sınırlı kalması nedeniyle araştırmacılar CNN ve tekrarlayan sinir ağlarını birleştiren hibrit yapılaraya yönelmiştir. Bu kapsamda geliştirilen Convolutional Recurrent Neural Network (CRNN) mimarileri, CNN katmanları ile akustik özellikleri öğrenirken LSTM veya BiLSTM katmanları ile zamansal ilişkileri modelleyebilmektedir. Oramas ve arkadaşları (2018), CRNN mimarilerinin müzik analizi problemlerinde CNN modellerine kıyasla daha güçlü zamansal temsil yeteneği sunduğunu göstermiştir.

Son yıllarda dikkat mekanizması (attention mechanism) temelli Transformer mimarileri de ses işleme alanında kullanılmaya başlanmıştır. Vaswani ve arkadaşları (2017) tarafından önerilen Transformer mimarisi, uzun menzilli bağımlılıkları öğrenebilme yeteneği sayesinde doğal dil işleme alanında önemli başarılar elde etmiş, daha sonra ses işleme problemlerine uyarlanmıştır. Gong ve arkadaşları (2021) tarafından geliştirilen Audio Spectrogram Transformer (AST) modeli, ses sınıflandırma problemlerinde başarılı sonuçlar elde etmiş ve Transformer tabanlı yaklaşımların ses alanında uygulanabilirliğini göstermiştir.

MER alanındaki veri setleri, kullanılan öznitelikler, değerlendirme metrikleri ve güncel yöntemler üzerine kapsamlı bir inceleme Han ve arkadaşları (2022) tarafından gerçekleştirilmiştir. Bu çalışma, müzik duygu analizi alanındaki güncel eğilimleri ortaya koymuş ve özellikle derin öğrenme tabanlı yöntemlerin son yıllarda baskın hale geldiğini göstermiştir.

Büyük dil modelleri ve multimodal yapay zeka sistemlerinin gelişmesiyle birlikte müzik duygu analizinde yeni araştırma alanları ortaya çıkmıştır. Google Gemini ve GPT tabanlı sistemler ses, görüntü ve metin gibi farklı veri türlerini birlikte işleyebilmektedir. Ancak mevcut literatürde multimodal büyük dil modellerinin

müzik duygu analizi performansını insan algısı ve geleneksel derin öğrenme modelleri ile doğrudan karşılaştıran çalışma sayısı oldukça sınırlıdır.

Ayrıca literatürdeki çalışmaların büyük bölümü yalnızca duygu tahmini üzerine odaklanmakta, elde edilen duygu bilgilerinin üretken yapay zeka sistemleri kullanılarak görsel sanat üretimine dönüştürülmesi incelenmemektedir. Son yıllarda Stable Diffusion, Midjourney ve FLUX gibi üretken görüntü modellerinin yaygınlaşmasıyla birlikte duygu temelli sanat üretimi araştırmaları ortaya çıkmaya başlamış olsa da müzik duygu analizi, insan algısı, derin öğrenme modelleri ve üretken sanat sistemlerini aynı platformda bütünleştiren çalışmalar oldukça sınırlıdır.

Bu çalışmada, literatürdeki söz konusu boşluğu doldurmayı amaçlamaktadır. Çalışmada DEAM veri seti üzerinde eğitilen CNN, CRNN, Transformer ve Ensemble modelleri karşılaştırılmıştır. İnsan katılımcılardan elde edilen duygu değerlendirmeleri ile Google Gemini 2.5 Flash modelinin çıktıları birlikte analiz edilmiştir. Ayrıca geliştirilen Emotion-to-Art Engine sistemi sayesinde müziklerden elde edilen duygu profilleri FLUX.1-schnell modeli kullanılarak soyut sanat eserlerine dönüştürülmüştür. Bu yönüyle çalışma, müzik duygu analizi ile üretken yapay zekayı bir araya getiren çok yönlü bir yaklaşım sunmaktadır.

3. VERİ SETLERİ VE VERİ TOPLAMA SÜRECİ

DEAM Veri Seti

Bu çalışmada müzik duygu analizi modellerinin eğitimi için DEAM (Database for Emotional Analysis of Music) veri seti kullanılmıştır. DEAM veri seti, müzik duygu analizi alanında yaygın olarak kullanılan ve sürekli Valence–Arousal etiketleri içeren önemli veri setlerinden biridir. Veri seti, MediaEval Emotion in Music Challenge kapsamında geliştirilmiş olup farklı müzik türlerinden oluşan 1802 adet müzik parçasını içermektedir (Aljanaki ve ark., 2017).

DEAM veri setinin en önemli özelliklerinden biri, müzik parçalarının yalnızca belirli duygu sınıfları ile değil, sürekli duygu değerleri ile etiketlenmiş olmasıdır. Böylece her müzik parçası için Valence ve Arousal değerleri ayrı ayrı temsil edilebilmektedir. Bu yaklaşım, müzik duygu analizinde yaygın olarak kullanılan boyutsal duygu modeline uygun bir yapı sunmaktadır.

Çalışmada kullanılan veri setinde her müzik parçası için çok sayıda katılımcı tarafından yapılan duygu değerlendirmelerinin ortalamaları kullanılmıştır. Veri setindeki müzik dosyaları model eğitim sürecinde standartlaştırılmış ve aynı ön işleme adımlarından geçirilmiştir.

Özellik	Değer
Veri Seti	DEAM
Parça Sayısı	1802
Duygu Modeli	Valence–Arousal
Etiket Türü	Sürekli
Örnekleme Frekansı	22050 Hz
Kullanılan Süre	30 saniye
Format	WAV

Tablo 3.1 DEAM Veri Setinin Temel Özellikleri

Veri seti içerisindeki etiketler iki boyuttan oluşmaktadır:

- Valence: Duygunun pozitif veya negatif olma derecesi
- Arousal: Duygunun enerji seviyesi

Bu etiketler regresyon problemi olarak ele alınmış ve modeller tarafından sürekli değerler şeklinde tahmin edilmiştir.

Anket Çalışması

Yapay zeka modellerinin performansını insan algısıyla karşılaştırabilmek amacıyla Google Forms üzerinden bir anket çalışması gerçekleştirilmiştir. Anket kapsamında katılımcılardan belirli müzik parçalarını dinlemeleri ve dinleme sonrasında hissettikleri duyguları değerlendirmeleri istenmiştir.

Çalışmada özellikle farklı duygusal karakterlere sahip olduğu literatürde belirtilen iki müzik parçası kullanılmıştır:

- Samuel Barber – Adagio for Strings
- Married Life – Michael Giacchino (Instrumental Version)

Katılımcılar müzikleri dinledikten sonra çeşitli duygu ifadelerini Likert ölçeği üzerinde değerlendirmiştir. Ayrıca yaş, cinsiyet ve müzik dinleme alışkanlıkları gibi demografik bilgiler de toplanmıştır.

Toplanan veriler daha sonra Valence–Arousal uzayına dönüştürülmüş ve insan duygu profilleri oluşturulmuştur. Bu profiller hem derin öğrenme modellerinin hem de Gemini modelinin tahminleriyle karşılaştırılmıştır.

Anket veri seti toplam 298 katılımcı yanıtından oluşmaktadır. Analizlerde eksik veya geçersiz kayıtlar temizlendikten sonra kullanılabilir veriler değerlendirilmiştir.

Özellik	Değer
Katılımcı Sayısı	298
Şarkı Sayısı	2
Değerlendirme Türü	Likert Ölçeği
Çıktı	Valence–Arousal
Demografik Bilgiler	Yaş, Cinsiyet, Dinleme Alışkanlığı

Tablo 3.2 Anket Verisinin Genel Özellikleri

DEAM Veri Seti Ön İşleme

Model eğitiminden önce ses verileri ve anket verileri çeşitli ön işleme adımlarından geçirilmiştir.

Ses verileri için uygulanan işlemler aşağıdaki gibidir:

1. Ses dosyalarının WAV formatına dönüştürülmesi
2. Mono kanala dönüştürülmesi
3. 22050 Hz örnekleme frekansına yeniden örneklenmesi
4. Tüm kayıtların 30 saniyelik sabit uzunluğa getirilmesi
5. Mel-Spektrogram dönüşümü
6. Amplitude-to-dB dönüşümü
7. Normalizasyon işlemleri

Mel-Spektrogram üretiminde aşağıdaki parametreler kullanılmıştır:

Parametre	Değer
Sample Rate	22050
FFT	2048
Hop Length	512
Mel Bin	128
Süre	30 saniye

Tablo 3.3 Mel-Spektrogram üretimindeki parametreler

Anket verileri için ise öncelikle eksik kayıtlar temizlenmiş, ardından Likert ölçeğindeki cevaplar sayısal değerlere dönüştürülmüştür. Pozitif ve negatif duygu göstergeleri ayrı gruplar halinde değerlendirilerek her katılımcı için Valence ve Arousal skorları hesaplanmıştır.

Bu ön işleme süreci sonucunda hem ses verileri hem de insan değerlendirmeleri ortak bir duygu uzayında temsil edilebilir hale getirilmiştir.

Veri Seti Ön-İşleme

Bu çalışmada kullanılan DEAM veri setindeki ses dosyaları ve anket verileri, hem CNN modelinin eğitimi hem de insan-yapay zeka karşılaştırmasının sağlıklı yapılabilmesi için çok aşamalı bir ön-işleme sürecinden geçirilmiştir.

Anket Verilerinin Ön-İşlemesi

Anket cevapları Likert 1–5 aralığında toplanmıştır. CNN ve Gemini çıktılarıyla karşılaştırılabilir olması için bu değerler 0–1 aralığına normalize edilmiştir:

$X_{norm} = (\frac{x-1}{4})$. Ardından pozitif ve negatif duygu gruplarının farkı kullanılarak Valence ve Arousal skorları 1–9 ölçeğine projeksiyon ile taşınmıştır:

$$Valence = 5 \oplus 4 \odot (Pozitif \ominus Negatif)$$

$$Arousal = 5 \oplus 4 \odot (YüksekEnerji \ominus DüşükEnerji)$$

Bu dönüşüm sayesinde insan anketleri, DEAM etiketleri ve Gemini çıktıları **aynı duygusal uzayda** karşılaştırılabilir hale getirilmiştir.

4. YÖNTEM VE KULLANILAN TEKNOLOJİLER

Bu çalışmada müzik duygu analizi problemi; derin öğrenme modelleri, multimodal yapay zeka sistemleri ve üretken yapay zeka teknolojileri kullanılarak ele alınmıştır. Sistem geliştirme sürecinde veri işleme, model eğitimi, analiz ve görselleştirme aşamalarında farklı teknolojilerden yararlanılmıştır.

Kullanılan Teknolojiler

Python

Projenin tamamı Python programlama dili kullanılarak geliştirilmiştir. Python'un veri bilimi, makine öğrenmesi ve yapay zeka alanlarında sunduğu geniş kütüphane desteği nedeniyle tercih edilmiştir. Ses işleme, veri analizi, model eğitimi, görsel üretimi ve web uygulaması geliştirme süreçlerinin tamamı Python ile gerçekleştirilmiştir.

PyTorch

Derin öğrenme modellerinin geliştirilmesi ve eğitilmesi amacıyla PyTorch kütüphanesi kullanılmıştır. PyTorch, dinamik hesaplama grafiği yapısı ve GPU desteği sayesinde büyük veri kümeleri üzerinde verimli model eğitimi gerçekleştirebildiği için tercih edilmiştir.

Bu çalışma kapsamında CNN, CRNN, Transformer ve Ensemble modellerinin tamamı PyTorch kullanılarak geliştirilmiştir.

Librosa

Ses verilerinin işlenmesi amacıyla Librosa kütüphanesinden yararlanılmıştır. Librosa; yeniden örnekleme (resampling), mel-spektrogram üretimi, frekans dönüşümleri ve ses sinyalinin analiz edilmesi gibi işlemleri gerçekleştirmek için kullanılmıştır.

Streamlit

Kullanıcı arayüzü için Streamlit frameworkü kullanılmıştır. Streamlit sayesinde model sonuçları, karşılaştırma grafikleri, demografik analizler ve yapay zeka çıktıları etkileşimli bir web arayüzü üzerinden sunulmuştur.

Google Gemini 2.5 Flash API

Multimodal yapay zeka analizleri için Google Gemini 2.5 Flash modeli kullanılmıştır. Bu model, yüklenen ses dosyalarını analiz ederek Valence ve Arousal tahminleri üretmekte ve müzik hakkında doğal dil açıklamaları oluşturabilmektedir.

FLUX.1-schnell

Müziklerden elde edilen duygu profillerinin görsel sanat eserlerine dönüştürülmesi amacıyla FLUX.1-schnell görüntü üretim modeli kullanılmıştır. Model, Emotion-to-Art Engine tarafından oluşturulan sanat yönlendirmelerini kullanarak soyut görseller üretmektedir.

DynamoDB Local

Analiz sonuçlarının saklanması amacıyla DynamoDB Local veritabanı kullanılmıştır. Böylece daha önce gerçekleştirilen analizler tekrar görüntülenebilmekte ve kullanıcıların geçmiş sonuçları sistem üzerinde tutulabilmektedir.

Derin Öğrenme Modelleri

CNN Modeli

CNN modeli, mel-spektrogram görüntülerinden duygu özelliklerini öğrenmek amacıyla kullanılmıştır. Model çok katmanlı konvolüsyon bloklarından oluşmakta ve son katmanda Valence ile Arousal değerlerini tahmin eden regresyon katmanları bulunmaktadır.

CRNN Modeli

CRNN modeli, CNN katmanları ile akustik özellik çıkarımı gerçekleştirirken BiLSTM katmanları ile zamansal ilişkileri modellemektedir. Bu yapı sayesinde müzik içerisindeki zaman bağımlılıkları daha etkin şekilde öğrenilebilmektedir.

Transformer Modeli

Transformer modeli, dikkat (attention) mekanizmasını kullanarak müzik sinyalindeki uzun menzilli ilişkileri öğrenmektedir. Mel-Spektrogram girdileri patch tabanlı yapıya dönüştürülerek Transformer Encoder katmanları tarafından işlenmektedir.

Ensemble Modeli

Tek bir model yerine birden fazla modelin çıktılarının birleştirilmesi amacıyla ensemble yaklaşımı kullanılmıştır.

Ensemble sisteminde:

- CNN Optimized (%30)

- CNN Baseline (%30)
- CRNN V2 (%40)

çıktıları ağırlıklı ortalama yöntemiyle birleştirilmiştir.

Bu yaklaşım farklı modellerin güçlü yönlerini bir araya getirerek daha düşük hata oranları elde edilmesini sağlamıştır.

Emotion-to-Art Engine

Bu çalışmada geliştirilen Emotion-to-Art Engine sistemi, insan katılımcılardan elde edilen duygu profillerini görsel sanat temsillerine dönüştürmek amacıyla tasarlanmıştır.

Sistem öncelikle duygu dağılımlarını analiz ederek bir Emotion Profile oluşturmaktadır. Daha sonra bu profil kullanılarak Art DNA, Color DNA ve Composition DNA bileşenleri üretilmektedir.

Oluşturulan sanat profili FLUX.1-schnell modeline aktarılmakta ve her müzik parçası için özgün soyut sanat eserleri oluşturulmaktadır.

Bu yapı, çalışmanın yalnızca müzik duygu analizi ile sınırlı kalmayıp üretken yapay zeka tabanlı sanat üretimine de katkı sunmasını sağlamaktadır.

5. SİSTEM TASARIMI

Bu bölümde geliştirilen müzik duygu analizi sisteminin genel mimarisi, modülleri arasındaki ilişkiler, veri akışı, veritabanı yapısı ve kullanıcı arayüzü tasarımı açıklanmaktadır. Sistem müzik duygu analizi, insan duygu algısının modellenmesi, yapay zeka tabanlı karşılaştırmalar ve duygu temelli sanat üretimini tek platform altında birleştirecek şekilde tasarlanmıştır.

Sistem Mimarisi


Geliştirilen sistem modüler bir yapı kullanılarak tasarlanmıştır. Bu yaklaşım sayesinde veri işleme, model çalıştırma, duygu analizi, görsel üretim ve kullanıcı arayüzü birbirinden bağımsız şekilde geliştirilebilmiştir.

Sistem genel olarak beş ana katmandan oluşmaktadır:

- Veri Katmanı
- Model Katmanı
- Analiz Katmanı

- Üretken Yapay Zeka Katmanı
- Sunum ve Kayıt Katmanı

Şekil 4.1'de sistemin genel mimarisi gösterilmektedir.



Şekil 5.1 Sistem Genel Mimarisi

Veri katmanı sistemin giriş bölümünü oluşturmaktadır. Bu katmanda DEAM veri seti ve kullanıcı anketlerinden elde edilen veriler yer almaktadır. Model katmanında farklı derin öğrenme mimarileri kullanılarak Valence ve Arousal tahminleri gerçekleştirilmektedir. Analiz katmanında insan değerlendirmeleri ile yapay zeka çıktıları karşılaştırılmaktadır. Üretken yapay zeka katmanında duygu profilleri görselleştirilmekte, son katmanda ise tüm sonuçlar kullanıcıya sunulmakta ve veritabanına kaydedilmektedir.

Veri Katmanı Tasarımı

Sistemin veri katmanı iki farklı veri kaynağından oluşmaktadır.

İlk veri kaynağı model eğitiminde kullanılan DEAM (Database for Emotional Analysis of Music) veri setidir. Veri seti 1802 adet müzik parçası ve bunlara ait Valence–Arousal etiketlerini içermektedir.

İkinci veri kaynağı ise proje kapsamında gerçekleştirilen kullanıcı anketlerinden elde edilen verilerdir. Katılımcılar belirli müzik parçalarını dinledikten sonra duygu değerlendirmeleri yapmış ve bu değerlendirmeler daha sonra Valence–Arousal skorlarına dönüştürülmüştür.

Bu iki veri kaynağı ortak bir duygu uzayında temsil edilerek insan algısı ile yapay zeka modellerinin karşılaştırılabilmesi sağlanmıştır.

Model Katmanı Tasarımı

Model katmanı sistemin çekirdeğini oluşturmaktadır. Bu katmanda müziklerden duygu tahmini gerçekleştiren farklı derin öğrenme mimarileri geliştirilmiş ve karşılaştırılmıştır.

Tüm modeller aynı veri bölünmesi kullanılarak eğitilmiştir:

- Eğitim Verisi: 1261 örnek
- Doğrulama Verisi: 271 örnek
- Test Verisi: 270 örnek
- Rastgelelik Tohumu (Seed): 42

Bu yaklaşım farklı model aileleri arasında eşit bir şekilde karşılaştırma yapılmasını sağlamıştır.

CNN Model Ailesi

CNN modelleri mel-spektrogram görüntülerini kullanarak müzik sinyalindeki akustik örüntüleri öğrenmektedir.

Proje kapsamında aşağıdaki CNN deneyleri gerçekleştirilmiştir:

- CNN Baseline
- CNN Learning Rate Deneyleri
- CNN Dropout Deneyleri
- CNN Weight Decay Deneyleri
- CNN SpecAugment Deneyleri
- CNN Noise Augmentation Deneyleri
- CNN Farklı Loss Fonksiyonu Deneyleri
- CNN Optimized

Deneyler sonucunda en başarılı tekil model CNN Optimized modeli olmuştur. Bu model;

- Daha derin CNN yapısı
- SpecAugment
- Gürültü artırma
- AdamW optimizasyonu
- MSE + CCC kayıp fonksiyonu

kullanılarak geliştirilmiştir.

Model ortalama RMSE açısından en başarılı tekil model olarak belirlenmiştir.

CRNN Model Ailesi

CRNN modelleri CNN ve BiLSTM katmanlarının birleşiminden oluşmaktadır.

Bu mimaride:

- CNN katmanları akustik özellikleri öğrenmektedir.
- BiLSTM katmanları zaman bağımlılıklarını modellemektedir.

Geliştirilen modeller:

- CRNN V1
- CRNN V1 BiLSTM
- CRNN V2

Özellikle CRNN V2 modeli daha güçlü CNN katmanları, çift BiLSTM yapısı ve gelişmiş veri artırma teknikleri kullanılarak geliştirilmiştir.

CRNN V2 modeli Valence korelasyonu açısından tüm tekil modeller arasında en yüksek sonucu üretmiştir.

Transformer Model Ailesi

Transformer mimarileri dikkat (Attention) mekanizması kullanarak müzik içerisindeki uzun menzilli ilişkileri öğrenmektedir.

Bu çalışma kapsamında:

- Transformer V1
- Transformer V2

olmak üzere iki farklı Transformer modeli geliştirilmiştir.

Mel-Spektrogram girdileri küçük parçalara ayrılarak Transformer Encoder katmanlarına aktarılmıştır. Böylece model müzik içerisindeki farklı bölümler arasındaki ilişkileri öğrenebilmektedir.

Deney sonuçları Transformer modellerinin CNN ve CRNN modellerinin gerisinde kaldığını göstermiştir.

CNN–Transformer Hibrit Modeli

Çalışma kapsamında CNN ve Transformer mimarilerini birleştiren hibrit bir model de geliştirilmiştir.

Bu yaklaşımda CNN katmanları yerel akustik özellikleri öğrenirken Transformer katmanları küresel ilişkileri modellemektedir.

Ancak deney sonuçları hibrit yapının beklenen performansı sağlayamadığını göstermiştir. Bunun temel nedenleri;

- Veri miktarının sınırlı olması,
- Model karmaşıklığının yüksek olması,
- Aşırı öğrenme eğilimi

olarak değerlendirilmektedir.

Ensemble Modelleri

Tek bir model yerine birden fazla modelin birlikte kullanılması amacıyla ensemble yaklaşımları geliştirilmiştir.

Bu kapsamda üç farklı yöntem uygulanmıştır:

Basit Ortalama Ensemble

CNN Optimized, CNN Baseline ve CRNN V2 modellerinin çıktıları eşit ağırlıklarla birleştirilmiştir.

Ağırlıklı Ensemble

Bu yöntemde modeller performanslarına göre ağırlıklandırılmıştır.

Model	Ağırlık
CNN Optimized	0.30
CNN Baseline	0.30
CRNN V2	0.40

Tablo 5.1 Model Ağırlıklandırması

Bu yaklaşım uygulamada kullanılan ana model olarak seçilmiştir. Çünkü düşük hata oranı ile yorumlanabilirliği bir arada sunmaktadır.

Stacking Ensemble

Stacking yaklaşımında temel modellerin çıktıları ikinci seviyede bir Ridge Regression modeli tarafından değerlendirilmiştir.

Deney sonuçlarında yüksek performans elde edilmesine rağmen uygulama tarafında daha sade ve anlaşılabilir olduğu için ağırlıklı ensemble yaklaşımı tercih edilmiştir.

Analiz Katmanı Tasarımı

Analiz katmanı sistemin karar verme ve karşılaştırma işlemlerinden sorumludur.

Bu katmanda aşağıdaki analizler gerçekleştirilmektedir:

- İnsan vs Model
- İnsan vs Gemini
- İnsan vs CNN vs Gemini
- Demografik Analiz
- Duygu Dağılımı Analizi
- Şarkılar Arası Karşılaştırma

Tüm analizler Valence–Arousal uzayında gerçekleştirilmektedir.

Bu yapı sayesinde farklı yöntemlerin insan duygu algısına ne kadar yakın sonuçlar üretebildiği değerlendirilebilmektedir.

Emotion-to-Art Engine

Emotion-to-Art Engine, kullanıcı anketlerinden elde edilen duygu dağılımlarını analiz ederek her müzik parçası için özgün bir sanat profili oluşturmaktadır. Sistemin ilk sürümünde yalnızca baskın duygular kullanılarak renk paleti oluşturulmakta ve bu bilgiler doğrudan görsel üretim modeline aktarılmaktaydı. Ancak yapılan testlerde benzer duygu dağılımlarına sahip şarkılar için üretilen görsellerin de birbirine benzediği gözlemlenmiştir. Bu problemi çözmek amacıyla çok katmanlı bir Emotion-to-Art Engine mimarisi geliştirilmiştir.

Yeni sistem aşağıdaki çalışma akışını kullanmaktadır:

Anket Verileri → İstatistiksel Analiz → Emotion Analysis → Emotion Profile → Art DNA → Style Engine → Prompt Generator → FLUX → Soyut Sanat Görseli

İlk aşamada kullanıcı anketlerinden elde edilen veriler üzerinde istatistiksel analizler gerçekleştirilmektedir. Bu analizler sonucunda şarkının duygusal karakterini temsil eden bir **Emotion Profile** oluşturulmaktadır.

Emotion Profile aşağıdaki psikometrik göstergelerden oluşmaktadır:

- Dominant Emotions (Baskın Duygular)

- Ortalama Valence
- Ortalama Arousal
- Emotional Intensity (Duygusal Yoğunluk)
- Emotional Diversity (Duygu Çeşitliliği)
- Entropy
- Positive Emotion Ratio
- Negative Emotion Ratio
- Emotional Balance

Bu göstergeler kullanılarak her şarkının duygu yapısı sayısal olarak tanımlanmaktadır.

Dominant Emotions

Katılımcıların seçtiği duygu etiketlerinin frekansları hesaplanmakta ve en yüksek oranlı duygular baskın duygular olarak belirlenmektedir.

Ortalama Valence ve Ortalama Arousal

Valence şarkının pozitif veya negatif yönünü temsil ederken, Arousal enerji seviyesini temsil etmektedir.

Bu değerler tüm katılımcılar üzerinden hesaplanarak genel duygu yönelimi belirlenmektedir.

Emotional Intensity

Duygusal yoğunluk katılımcılar arasındaki değişkenliği göstermektedir.

Bu amaçla standart sapma hesaplanmakta ve yüksek değişkenlik durumunda daha karmaşık sanat kompozisyonları tercih edilmektedir.

Emotional Diversity

Duygu çeşitliliği şarkının ne kadar farklı duygu içerdiğini göstermektedir.

Yüksek çeşitlilik durumunda sistem daha deneysel sanat stillerine yönelmektedir.

Entropy

Duygu dağılımındaki düzensizlik Shannon Entropy kullanılarak hesaplanmaktadır.

Düşük entropy sade kompozisyonlara, yüksek entropy ise daha karmaşık ve çok katmanlı yapılara yönlendirmektedir.

Positive ve Negative Emotion Ratio

Pozitif ve negatif duyguların toplam dağılım içerisindeki oranları hesaplanmaktadır.

Bu oranlar renk seçimi, ışık kullanımı ve atmosfer oluşturulmasında kullanılmaktadır.

Emotional Balance

Pozitif ve negatif duygu oranlarının farkı alınarak genel duygu dengesi hesaplanmaktadır.

Bu değer sistemin genel sanat yönelimini belirlemektedir.

Emotion Profile oluşturulduktan sonra sistem her şarkı için benzersiz bir **Art DNA** üretmektedir. Art DNA, şarkının görsel sanat kimliğini temsil eden çok katmanlı bir yapıdır ve aşağıdaki bileşenlerden oluşmaktadır:

- Style DNA
- Color DNA
- Composition DNA
- Motion DNA
- Texture DNA
- Lighting DNA
- Symbolism Engine
- Spatial Layout

Style Engine, Emotion Profile verilerini kullanarak uygun sanat akımlarını belirlemektedir. Sistem tek bir sanat stili seçmek yerine birden fazla sanat akımını harmanlayarak özgün bir sanat dili oluşturmaktadır. Örneğin huzurlu şarkılar için Minimalism ve Japanese Ink Wash, yüksek enerjili şarkılar için ise Abstract Expressionism ve Action Painting yaklaşımları birlikte kullanılabilir.

Color DNA modülü, şarkının duygusal yapısına göre ağırlıklı renk dağılımları oluşturmaktadır. Böylece her şarkı yalnızca belirli renk isimleriyle değil, kendine özgü bir renk kimliğiyle temsil edilmektedir.

Composition DNA, sistemin özgünlük sağlayan en önemli bileşenlerinden biridir. Bu modül görsel öğelerin tuval üzerindeki mekânsal organizasyonunu belirlemektedir. Kullanılan kompozisyon yapıları arasında Golden Ratio, Radial Composition, Spiral Motion, Asymmetric Balance, Floating Geometry, Fragmented Layers, Negative Space, Organic Flow, Diagonal Movement ve Circular Harmony gibi farklı sanat kompozisyonları bulunmaktadır. Böylece aynı renk paletine sahip iki şarkı bile farklı kompozisyon yapıları nedeniyle tamamen farklı görsel çıktılar üretebilmektedir.

Buna ek olarak sistem;

- Motion DNA ile görsel hareket karakterini,
- Texture DNA ile yüzey dokularını,
- Lighting DNA ile ışık yapısını,
- Symbolism Engine ile duyguların görsel sembollerini,
- Spatial Layout modülü ile mekânsal yerleşimi

otomatik olarak belirlemektedir.

FLUX Görsel Üretim Modülü

Emotion-to-Art Engine tarafından oluşturulan tüm bilgiler Prompt Generator modülünde birleştirilmektedir.

Oluşturulan prompt içerisinde:

- Emotion Profile
- Art Style
- Color DNA
- Composition DNA
- Motion DNA
- Texture DNA
- Lighting DNA
- Symbolism
- Spatial Layout

bilgileri yer almaktadır.

Prompt oluşturulurken ayrıca modele;

- Museum Quality
- Contemporary Fine Art
- Ultra Detailed
- Cinematic
- Original
- Complex
- Layered
- No People
- No Text
- No Logo
- No Watermark

gibi kalite ve içerik yönlendirmeleri verilmektedir.

Bunun yanında:

- Avoid repetitive layouts

- Avoid repetitive color balance
- Avoid repetitive geometry
- Avoid repetitive symbolism

kısıtları kullanılarak farklı şarkılar için benzer görseller üretilmesi engellenmektedir.

Son aşamada oluşturulan sanat profili ve detaylı prompt yapısı **FLUX.1-schnell** modeline aktarılmaktadır. Model bu bilgileri kullanarak müziğin duygu yapısını temsil eden yüksek çeşitlilikte soyut sanat eserleri üretmektedir.

Sistem tamamen rastgele çalışmamaktadır. Her şarkı için deterministik bir Art DNA oluşturulmakta ve şarkının benzersiz kimliği kullanılarak sabit bir seed değeri üretilmektedir. Böylece aynı şarkı tekrar analiz edildiğinde aynı sanat kimliği ve benzer görsel çıktılar elde edilebilmektedir. Bu yaklaşım sistemin tekrarlanabilirliğini ve açıklanabilirliğini artırmaktadır.

Sonuç olarak Emotion-to-Art Engine, psikometrik analizleri, duygu modellemesini, sanat teorisini ve üretken yapay zeka teknolojilerini bir araya getirerek müziklerden elde edilen duygu verilerini özgün ve açıklanabilir sanat eserlerine dönüştüren bütünlük bir yapı sunmaktadır.

Veritabanı Tasarımı

Sistemde analiz geçmişlerinin saklanabilmesi amacıyla DynamoDB Local kullanılmıştır.

Veritabanında aşağıdaki bilgiler tutulmaktadır:

Alan	Açıklama
AnalysisID	Analiz kimliği
SongName	Şarkı adı

Timestamp	Analiz zamanı
Valence	Valence değeri
Arousal	Arousal değeri
ModelName	Kullanılan model
GeminiResult	Gemini sonucu
GeneratedImage	Üretilen görsel

Tablo 5.2 Veritabanı Tasarımı

Bu yapı sayesinde geçmiş analizler tekrar görüntülenebilmekte ve sonuçlar karşılaştırılabilmektedir.

Kullanıcı Arayüzü Tasarımı

Sistem arayüzü Streamlit frameworkü kullanılarak geliştirilmiştir.

Arayüz aşağıdaki modüllerden oluşmaktadır:

1. Model Karşılaştırma
2. İnsan–Model Karşılaştırması
3. İnsan–Gemini Karşılaştırması
4. Demografik Analiz
5. Duygu Dağılımı Analizi
6. Emotion-to-Art Analizi
7. Geçmiş Analizler

Kullanıcılar ses dosyası yükleyebilmekte, model seçebilmekte ve analiz sonuçlarını etkileşimli grafikler üzerinden görüntüleyebilmektedir.

Modüller Arası İlişkiler

Sistemdeki modüller birbirleriyle veri akışı üzerinden haberleşmektedir.

Veri katmanı model katmanını beslemekte, model katmanı analiz katmanına duygu tahminleri göndermekte, analiz katmanı ise sonuçları üretken yapay zeka katmanına aktarmaktadır.

Üretken yapay zeka katmanında oluşturulan görseller ve analiz sonuçları kullanıcı arayüzüne gönderilmekte, aynı zamanda DynamoDB veritabanına kaydedilmektedir.

Bu mimari sayesinde sistem genişletilebilir, sürdürülebilir ve modüler bir yapıya sahip olmaktadır.

6. UYGULAMA VE GELİŞTİRME SÜRECİ

Geliştirme süreci modüler bir yapı kullanılarak gerçekleştirilmiştir. Bu yaklaşım sayesinde her bileşen bağımsız olarak geliştirilebilmiş, test edilebilmiş ve daha sonra sistem içerisinde bütünleştirilmiştir.

Veri Hazırlama Modülü


Geliştirme sürecinin ilk aşamasında model eğitiminde kullanılacak veri setleri hazırlanmıştır.

Bu amaçla DEAM veri seti kullanılmıştır. Veri setindeki müzik dosyaları standart bir yapıya dönüştürülmüş ve tüm kayıtlar aynı örnekleme frekansında işlenmiştir.

Ses verileri aşağıdaki işlemlerden geçirilmiştir:

- WAV formatına dönüştürme
- Mono kanala dönüştürme
- 22050 Hz yeniden örnekleme
- 30 saniyelik sabit uzunluk oluşturma
- Mel-Spektrogram üretimi
- Normalizasyon

Bu aşama sonunda tüm müzik dosyaları derin öğrenme modellerinin kullanabileceği standart giriş formatına dönüştürülmüştür.



Şekil 6.1 Örnek Mel-Spektrogram görselleri

Derin Öğrenme Modüllerinin Geliştirilmesi

Veri hazırlama sürecinin ardından farklı model mimarileri geliştirilmiştir.

İlk olarak CNN Baseline modeli oluşturulmuş ve referans model olarak kullanılmıştır. Daha sonra öğrenme oranı, dropout, weight decay, veri artırma yöntemleri ve kayıp fonksiyonları üzerinde çok sayıda deney gerçekleştirilmiştir.

CNN deneylerinin ardından müziğin zamansal yapısını modelleyebilmek amacıyla CRNN mimarileri geliştirilmiştir. Bu modellerde CNN katmanları ile özellik çıkarımı yapılırken BiLSTM katmanları ile zaman bağımlılıkları öğrenilmiştir.

Bir sonraki aşamada Transformer tabanlı modeller geliştirilmiş ve dikkat mekanizmasının müzik duygu analizi üzerindeki etkisi incelenmiştir.

Son olarak CNN ve Transformer katmanlarını bir araya getiren hibrit model tasarlanmış ve performansı değerlendirilmiştir.

Model geliştirme sürecinde her deney için ayrı konfigürasyon dosyaları oluşturulmuş, eğitim geçmişleri kaydedilmiş ve sonuçlar sistematik olarak karşılaştırılmıştır.

İnsan Duygu Analizi Modülü

Sistemin önemli bileşenlerinden biri insan duygu analiz modülüdür.

Bu modülde katılımcılardan belirli müzik parçalarını dinlemeleri ve hissettikleri duyguları değerlendirmeleri istenmiştir.

Anket sonuçları öncelikle temizlenmiş ve eksik veriler ayıklanmıştır.

Daha sonra:

- Likert cevapları normalize edilmiş,
- Pozitif ve negatif duygu grupları oluşturulmuş,
- Valence ve Arousal skorları hesaplanmıştır.

Bu süreç sonunda insan duygu algısı sayısal olarak temsil edilmiş ve yapay zeka çıktılarıyla karşılaştırılabilir hale getirilmiştir.

Gemini Entegrasyon Modülü

Sistemin bir diğer bileşeni Google Gemini 2.5 Flash entegrasyonudur.

Bu modülde ses dosyaları Gemini API üzerinden modele gönderilmektedir.

Gemini modeli:

- Müziği yorumlamakta,
- Duygusal özellikleri analiz etmekte,
- Valence ve Arousal tahminleri üretmekte,
- Açıklayıcı metinler oluşturmaktadır.

Elde edilen sonuçlar insan değerlendirmeleri ve derin öğrenme modellerinin çıktıları ile karşılaştırılmaktadır.

Bu modül sayesinde geleneksel derin öğrenme yaklaşımları ile büyük multimodal yapay zeka sistemleri aynı platform üzerinde değerlendirilebilmektedir.

Emotion-to-Art Engine Modülü

Bu çalışma kapsamında geliştirilen Emotion-to-Art Engine sistemi, müziklerden elde edilen duygu profillerini görsel sanat eserlerine dönüştürmektedir.

Sistem öncelikle insan katılımcılardan elde edilen duygu dağılımlarını analiz etmektedir.

Daha sonra:

- Emotion Profile
- Art DNA
- Color DNA

- Composition DNA

oluşturulmaktadır.

Bu bilgiler görsel üretim modeline aktarılmakta ve müziğin duygusal karakterini temsil eden özgün sanat yönlendirmeleri oluşturulmaktadır.

FLUX Görsel Üretim Modülü

Emotion-to-Art Engine tarafından oluşturulan sanat profilleri FLUX.1-schnell modeline gönderilmektedir.

FLUX modeli:

- Sanat stili
- Renk yapısı
- Kompozisyon tercihleri
- Duygusal yoğunluk

bilgilerini kullanarak soyut sanat görselleri üretmektedir.

Bu sayede müziklerin yalnızca sayısal duygu skorları değil, aynı zamanda görsel temsilleri de elde edilmektedir.

Kullanıcı Arayüzünün Geliştirilmesi

Sistemin kullanıcı arayüzü Streamlit frameworkü kullanılarak geliştirilmiştir.

Arayüz aşağıdaki temel modüllerden oluşmaktadır:

- Model Karşılaştırma
- İnsan–Model Karşılaştırması
- İnsan–Gemini Karşılaştırması
- Demografik Analiz
- Duygu Dağılımı Analizi
- Emotion-to-Art Analizi
- Geçmiş Analizler

Veritabanı ve Kayıt Yönetimi

Analiz geçmişlerinin saklanabilmesi amacıyla DynamoDB Local kullanılmıştır.

Her analiz sonucunda aşağıdaki bilgiler kaydedilmektedir:

- Şarkı bilgileri
- Analiz zamanı

- Model sonuçları
- Gemini sonuçları
- Üretilen görseller

Bu yapı sayesinde kullanıcılar geçmiş analizlerine erişebilmekte ve sonuçları yeniden inceleyebilmektedir.

Karşılaşılan Teknik Problemler ve Çözüm Süreci

Geliştirme sürecinde çeşitli teknik problemlerle karşılaşmıştır.

Model Performans Problemleri

İlk CNN modellerinde aşırı öğrenme (overfitting) gözlemlenmiştir. Bu problem dropout, veri artırma teknikleri ve weight decay kullanılarak azaltılmıştır.

Model Sonuçlarının Kararsızlığı

Farklı modellerin farklı metriklerde güçlü sonuçlar üretmesi nedeniyle tek bir model seçmek zorlaşmıştır. Bu problem ensemble yaklaşımı kullanılarak çözülmüştür.

İnsan ve Yapay Zeka Çıktılarının Karşılaştırılması

İnsan anketleri ile model çıktıları farklı ölçeklerde üretilmiştir. Bu nedenle tüm veriler ortak Valence–Arousal uzayına dönüştürülerek karşılaştırılabilir hale getirilmiştir.

Görsel Üretim Süreci

Duygu profillerinin doğrudan görüntü modeline verilmesi tutarsız sonuçlar üretmiştir. Bu nedenle Emotion-to-Art Engine geliştirilmiş ve duygu bilgilerinin yapılandırılmış sanat profillerine dönüştürülmesi sağlanmıştır.

Bu çözümler sonucunda sistem daha kararlı, yorumlanabilir ve genişletilebilir bir yapıya kavuşturulmuştur.

7. TEST VE DEĞERLENDİRME

Bu bölümde geliştirilen müzik duygu analizi sisteminin performansı değerlendirilmiş ve elde edilen sonuçlar analiz edilmiştir. Test sürecinde hem derin öğrenme modelleri hem de insan katılımcılardan elde edilen veriler kullanılmıştır. Ayrıca Gemini 2.5 Flash modeli ve geliştirilen Emotion-to-Art Engine sistemi de değerlendirme kapsamına alınmıştır.

Test Ortamı

Tüm deneyler aynı veri bölünmesi kullanılarak gerçekleştirilmiştir.

Veri seti aşağıdaki şekilde ayrılmıştır:

Veri Kümesi	Örnek Sayısı
Eğitim	1261
Doğrulama	271
Test	270
Toplam	1802

Tablo 7.1 Veri Seti Ayrımı

Modellerin karşılaştırılabilir sonuçlar üretebilmesi amacıyla tüm deneylerde aynı rastgelelik tohumu (Seed=42) kullanılmıştır.

Model performansları aşağıdaki metrikler kullanılarak değerlendirilmiştir:

- RMSE (Root Mean Square Error)
- MAE (Mean Absolute Error)
- Pearson Korelasyon Katsayısı
- CCC (Concordance Correlation Coefficient)

RMSE ve MAE değerlerinin düşük olması daha başarılı sonuçları ifade ederken, Pearson ve CCC değerlerinin yüksek olması model tahminlerinin gerçek etiketlere daha yakın olduğunu göstermektedir.

Derin Öğrenme Modellerinin Performans Değerlendirilmesi

Çalışma kapsamında CNN, CRNN, Transformer ve hibrit modeller test edilmiştir.

Elde edilen sonuçlar Tablo 7.2'de verilmiştir.

S i r a	Model	RMSE -V	RMSE -A	Pears on-V	Pearso n-A	MAE- V	MAE- A	Ortala ma RMSE	Ortala ma Pearson	Açıkl ama
1	cnn_optimized	0.8448	0.8174	0.7095	0.7789	0.6709	0.6455	0.8311	0.7442	Derin CNN (32-64-128-256)
2	cnn_baseline	0.8404	0.8332	0.7152	0.7757	0.6658	0.6601	0.8368	0.7455	Temel CNN modeli
3	cnn_v2_mse_ccc	0.8392	0.8414	0.7082	0.7669	0.6697	0.6707	0.8403	0.7375	MSE + CCC kayıp fonksiyonu
4	cnn_v2_specaugment_noise	0.8339	0.8493	0.7098	0.7602	0.6665	0.6723	0.8416	0.7350	SpecAugment + hafif gürültü
5	cnn_v2_dropout_03	0.8455	0.8381	0.7062	0.7648	0.6708	0.6742	0.8418	0.7355	Dropout = 0.3

6	cnn_v2_ lr_1e4	0.8524	0.8336	0.7059	0.7709	0.6699	0.6616	0.8430	0.7384	Öğren me oranı = 1e-4
7	crnn_v2	0.8500	0.8363	0.7160	0.7678	0.6919	0.6624	0.8431	0.7419	Güçlü CNN + BiLST M(2)
8	crnn_v1	0.8561	0.8422	0.7022	0.7692	0.6783	0.6754	0.8492	0.7357	Basit CRN N
9	cnn_v2_ smoothl 1	0.8493	0.8516	0.6993	0.7575	0.6798	0.6781	0.8505	0.7284	Smoot hL1 kaybı
10	cnn_v2_ wd_1e4	0.8555	0.8467	0.7024	0.7632	0.6785	0.6747	0.8511	0.7328	Weigh t Decay = 1e-4
11	cnn_v2_ specaug ment	0.8600	0.8453	0.7092	0.7703	0.6896	0.6709	0.8527	0.7397	SpecA ugmen t
12	cnn_v2_ dropout_ 04	0.8456	0.8612	0.6975	0.7598	0.6766	0.6905	0.8534	0.7286	Dropo ut = 0.4

1 3	cnn_v2_ wd_1e5	0.8456	0.8612	0.6975	0.7598	0.6766	0.6905	0.8534	0.7286	Weigh t Decay = 1e-5
1 4	cnn_v2_ noaug	0.8456	0.8612	0.6975	0.7598	0.6766	0.6905	0.8534	0.7286	Veri artırım ı yok
1 5	cnn_v2_ lr_3e4	0.8456	0.8612	0.6975	0.7598	0.6766	0.6905	0.8534	0.7286	Öğren me oranı = 3e-4
1 6	cnn_v2_ opt_ada m	0.8456	0.8612	0.6975	0.7598	0.6766	0.6905	0.8534	0.7286	Adam optimi zasyo nu
1 7	cnn_v2_ mse	0.8456	0.8612	0.6975	0.7598	0.6766	0.6905	0.8534	0.7286	MSE kaybı
1 8	crnn_v1 _bilstm	0.8599	0.8477	0.6985	0.7622	0.6760	0.6754	0.8538	0.7303	CRN N + BiLST M
1 9	cnn_v2_ wd_0	0.8476	0.8637	0.7015	0.7559	0.6834	0.6874	0.8556	0.7287	Weigh t Decay = 0

20	cnn_v2_dropout_05	0.8522	0.8773	0.6888	0.7372	0.6824	0.6993	0.8648	0.7130	Dropout = 0.5
21	cnn_v2_lr_1e3	0.8556	0.8904	0.6901	0.7490	0.6878	0.7111	0.8730	0.7196	Öğrenme oranı = 1e-3
22	transformer_v2	0.8963	0.9025	0.6597	0.7205	0.7280	0.7021	0.8994	0.6901	İyileştirilmiş Audio Transformer
23	transformer_v1	0.9441	0.9936	0.6115	0.6582	0.7547	0.7829	0.9689	0.6348	Temel Audio Transformer
24	cnn_transformer_v1	1.0852	1.2899	0.4716	0.4838	0.8713	1.0354	1.1875	0.4777	CNN + Transformer hibrit

Tablo 7.2 Model Performans Sonuçları

Sonuçlar incelendiğinde CNN tabanlı modellerin genel olarak en dengeli performansı sergilediği görülmektedir.

Özellikle CNN Optimized modeli;

- düşük hata oranı,
- yüksek korelasyon değeri,
- dengeli Valence ve Arousal tahminleri

ile en başarılı tekil model olmuştur.

CRNN modelleri özellikle Valence tahminlerinde güçlü sonuçlar üretmiştir. Bunun temel nedeni BiLSTM katmanlarının müziğin zamansal yapısını daha başarılı şekilde modelleyebilmesidir.

Transformer modelleri ise beklenen performansa ulaşamamıştır. Bunun nedeni veri setinin büyüklüğünün Transformer mimarilerinin ihtiyaç duyduğu ölçeğin altında kalması olabilir.

Ensemble Modellerinin Değerlendirilmesi

Tekil modellerin performanslarını artırmak amacıyla ensemble yöntemleri uygulanmıştır.

Çalışmada üç farklı ensemble yaklaşımı değerlendirilmiştir:

- Basit Ortalama Ensemble
- Ağırlıklı Ensemble
- Stacking Ensemble

Elde edilen sonuçlar Tablo 6.3'de verilmiştir.

Model	RMS E-V	RMSE -A	Pearso n-V	Pearso n-A	Ortalama RMSE	Ortalam a Pearson
ensemble_weighted	0.8239	0.8033	0.7317	0.7911	0.8136	0.7614
ensemble_simple_a verage	0.8242	0.8052	0.7309	0.7926	0.8147	0.7617
cnn_optimized	0.8448	0.8174	0.7095	0.7789	0.8311	0.7442
cnn_baseline	0.8404	0.8332	0.7152	0.7757	0.8368	0.7455

crnn_v2	0.8500	0.8363	0.7160	0.7678	0.8431	0.7419
---------	--------	--------	--------	--------	--------	--------

Tablo 7.3 Ensemble Sonuçları

Sonuçlar incelendiğinde ensemble yöntemlerinin tekil modellerden daha başarılı olduğu görülmektedir.

Özellikle ağırlıklı ensemble modeli:

- Ortalama RMSE = 0.8136

değeri ile en başarılı canlı sistem performansını göstermiştir.

Bu sonuç, farklı model ailelerinin güçlü yönlerinin birleştirilmesinin müzik duygu analizinde önemli avantaj sağladığını göstermektedir.

İnsan ve Yapay Zeka Karşılaştırması

Bu çalışmanın temel amaçlarından biri insan algısı ile yapay zeka tahminlerini karşılaştırmaktır.

Bu amaçla kullanıcı anketlerinden elde edilen Valence–Arousal skorları ile model çıktıları karşılaştırılmıştır.

Karşılaştırmalar aşağıdaki başlıklarda gerçekleştirilmiştir:

- İnsan vs CNN
- İnsan vs CRNN
- İnsan vs Ensemble
- İnsan vs Gemini

Elde edilen sonuçlar göstermektedir ki yapay zeka modelleri genel duygu eğilimlerini başarıyla yakalayabilmektedir. Ancak bazı durumlarda insanların öznel duygu algısı ile model tahminleri arasında farklılıklar oluşabilmektedir.

Bu durum müzik duygu analizinin yalnızca akustik özelliklerle açıklanamayacağını göstermektedir.

Gemini Performansının Değerlendirilmesi

Gemini 2.5 Flash modeli ses dosyaları üzerinde analiz gerçekleştirmiş ve Valence–Arousal tahminleri üretmiştir.

Gemini sonuçları insan değerlendirmeleri ile karşılaştırılmıştır.

Analizler sonucunda Gemini modelinin:

- genel duygu yönelimlerini doğru yakalayabildiği,
- açıklayıcı yorumlar üretebildiği,
- ancak bazı durumlarda enerji seviyelerini yanlış yorumlayabildiği

gözlemlenmiştir.

Bu sonuçlar multimodal büyük dil modellerinin müzik duygu analizi alanında kullanılabileceğini göstermektedir.

Emotion-to-Art Engine Değerlendirmesi

Emotion-to-Art Engine sisteminin değerlendirilmesinde farklı şarkılar için üretilen görseller incelenmiştir.

İlk sürümde benzer duygu dağılımlarına sahip şarkılar için benzer görseller üretildiği gözlemlenmiştir.

Geliştirilen Art DNA yaklaşımı sonrasında:

- daha yüksek görsel çeşitlilik,
- daha güçlü sembolizm,
- daha tutarlı sanat kimlikleri

elde edilmiştir.


Composition DNA, Motion DNA ve Symbolism Engine modülleri sistemin özgünlük düzeyini önemli ölçüde artırmıştır.

Bu sonuçlar Emotion-to-Art Engine mimarisinin amacına ulaştığını göstermektedir.

Sistemin Kullanım Akışı

Geliştirilen uygulama Streamlit frameworkü kullanılarak web tabanlı bir yapı şeklinde geliştirilmiştir. Kullanıcı uygulamayı başlattığında sistem ana ekranı görüntülenmektedir.

Şekil 7.1'te uygulamanın başlangıç ekranı gösterilmektedir.




Şekil 7.1 Uygulama Başlangıç ekranı

Uygulama ilk açıldığında sistem gerekli yapılandırma kontrollerini gerçekleştirmektedir. Bu aşamada Google AI Studio üzerinden alınan Gemini API anahtarı ve Hugging Face platformu üzerinden alınan FLUX API erişim bilgileri güvenli şekilde yüklenmektedir.

Başlatma işlemi tamamlandıktan sonra kullanıcıya sistem hakkında genel bilgiler sunulmakta ve analiz modüllerine erişim sağlanmaktadır. Sol tarafta bulunan menü aracılığıyla kullanıcı farklı analiz ekranları arasında geçiş yapabilmektedir.

İlk aşamada kullanıcı analiz etmek istediği müzik veya analiz kategorisini seçmektedir. Sistem seçilen verileri yükledikten sonra ilgili analiz modülünü çalıştırmaktadır.

Şekil 7.2'de model karşılaştırma ekranı gösterilmektedir.



Şekil 7.2 Model Karşılaştırma Ekranı

Bu ekranda kullanıcı farklı yapay zeka modellerinin performans sonuçlarını görüntüleyebilmektedir. CNN, CRNN, Transformer ve Ensemble modellerinin sonuçları grafikler ve performans tabloları aracılığıyla sunulmaktadır. Böylece kullanıcı modeller arasındaki başarı farklarını inceleyebilmektedir.

Kullanıcı daha sonra İnsan–Yapay Zeka Karşılaştırması sekmesine geçerek insan katılımcılardan elde edilen sonuçları yapay zeka çıktıları ile karşılaştırabilmektedir.

Şekil 7.3'te İnsan–Gemini karşılaştırma ekranı gösterilmektedir.

Stop

Deploy

Google Gemini API Anahtarı

Gemini API Key

Şarkı Seçimi

Şarkı Seç

Barber: Adagio for Strings

Şarkı Dosyası

'Barber: Adagio for Strings' şarkısını yükleyin (.wav, .mp3)

Drag and drop file here

Limit 200MB per file • WAV, MP3

Browse files

Adagio-for-strings.mp3

9.5MB

Gemini AI ile Analiz Et


Dosya Gemini sunucularına yükleniyor...

Dosya hazır, analiz başlıyor...

Gemini AI analizi tamamlandı

Şekil 7.3 İnsan–Gemini karşılaştırma ekranı

42




Şekil 7.4 VA Duygu uzayında Gemini analizi ve insan duygusu farkı

Bu bölümde insan katılımcıların oluşturduğu duygu profilleri ile Gemini 2.5 Flash modelinin ürettiği sonuçlar aynı grafik üzerinde gösterilmektedir. Gemini analizleri Google AI Studio API servisi üzerinden gerçekleştirilmektedir. Kullanıcı analiz işlemini başlattığında ilgili ses verileri Gemini modeline gönderilmekte ve model tarafından üretilen Valence–Arousal tahminleri ile açıklayıcı yorumlar sisteme aktarılmaktadır. Kullanıcı böylece yapay zeka ve insan algısı arasındaki benzerlikleri ve farklılıkları inceleyebilmektedir.

Demografik analiz ekranında ise kullanıcı yaş, cinsiyet ve müzik dinleme alışkanlığı gibi değişkenlerin duygu algısı üzerindeki etkilerini görüntüleyebilmektedir.

Şekil 7.5'te **İnsan – Seçili Model – Gemini Karşılaştırma** ekranı gösterilmektedir.




Şekil 7.5'te İnsan – Seçili Model – Gemini Karşılaştırma ekranı

Bu bölümde, insan katılımcılardan elde edilen duygu analiz sonuçları, kullanıcı tarafından seçilen makine öğrenmesi modeli ve Gemini modeli tarafından üretilen duygu analizleri aynı ekran üzerinde karşılaştırmalı olarak sunulmaktadır. Sistem, her üç kaynaktan elde edilen **Valence (duygusal yönelim)** ve **Arousal (uyarılmışlık/enerji seviyesi)** değerlerini ortak bir görselleştirme üzerinde göstererek sonuçların benzerlik ve farklılıklarının incelenmesine olanak sağlamaktadır.

Kullanıcı öncelikle analiz edilmek istenen şarkıyı seçmekte ve ardından karşılaştırmada kullanılacak yapay zeka modelini belirlemektedir. Seçilen model, proje kapsamında geliştirilen veya entegre edilen makine öğrenmesi modeli aracılığıyla şarkıya ait duygu tahminlerini üretmektedir. Aynı anda Gemini modeli de ilgili şarkıyı analiz ederek kendi Valence ve Arousal tahminlerini oluşturmaktadır. İnsan katılımcılardan elde edilen ortalama duygu değerleri ise veri tabanından alınarak karşılaştırmaya dahil edilmektedir.

Elde edilen sonuçlar grafiksel(Şekil 7.6) ve sayısal(Şekil 7.7) olarak aynı arayüz üzerinde gösterilmekte, böylece kullanıcı insan algısı, seçili yapay zeka modeli ve Gemini modeli arasındaki benzerlikleri ve farklılıkları doğrudan gözlemleyebilmektedir. Bu karşılaştırma sayesinde farklı yapay zeka modellerinin insan duygu algısına ne derece yakın sonuçlar ürettiği değerlendirilebilmekte ve modellerin performansları yorumlanabilmektedir.




Şekil 7.6 Üçlü yaklaşımın grafiksel karşılaştırması




Şekil 7.7 Üçlü yaklaşımın sayısal karşılaştırması

Karşılaştırma ekranı ayrıca açıklayıcı değerlendirme metinleri ve performans göstergeleri sunarak kullanıcıya yalnızca sayısal sonuçları değil, bu sonuçların anlamını da yorumlama imkanı sağlamaktadır. Böylece sistem, insan duygu algısı ile farklı yapay zeka yaklaşımlarını aynı platform üzerinde analiz edebilen karşılaştırmalı bir karar destek aracı olarak kullanılabilir.


Şekil 7.8'de demografik analiz ekranı gösterilmektedir.




Şekil 7.8 Demografik Analiz Ekranı



Şekil 7.9 Yaş Gruplarına Göre VA Dağılımları




Şekil 7.10 Cinsiyete göre VA bar chart




Şekil 7.11 Müzik dinlemeden önceki ve sonraki duygu durumu

Sistemin en özgün modüllerinden biri olan Emotion-to-Art ekranında kullanıcı, anketlerden elde edilen duygu analiz sonuçlarının görsel sanat eserlerine nasıl dönüştürüldüğünü inceleyebilmektedir.

Şekil 7.12'de Emotion-to-Art ekranı gösterilmektedir.



Şekil 7.12 Soyut Görsel Oluşturma Ekranı



7.13 Barber:Adiogo for Strings parçasının oluşturulmuş soyut görseli

Bu ekranda öncelikle Emotion Profile bilgileri görüntülenmektedir. Ardından sistem tarafından oluşturulan Art DNA, Color DNA ve Composition DNA bileşenleri gösterilmektedir. Son aşamada oluşturulan sanat profili Hugging Face altyapısı üzerinden erişilen FLUX.1-schnell modeline gönderilmektedir. Model tarafından üretilen soyut sanat görseli kullanıcı arayüzünde görüntülenmektedir. Şekil 7.10'da bir görsel örneği eklenmiştir.

Kullanıcı ayrıca Geçmiş Analizler ekranına erişerek daha önce gerçekleştirilen analizleri görüntüleyebilmektedir. Bu veriler DynamoDB Local üzerinde saklanmaktadır.

Sistemin Güçlü ve Zayıf Yönleri

Güçlü Yönler

- Birden fazla yapay zeka modelini aynı platformda birleştirmektedir.
- İnsan algısı ile yapay zekayı karşılaştırabilmektedir.
- Ensemble yaklaşımı yüksek performans sağlamaktadır.
- Gemini entegrasyonu sayesinde multimodal analiz yapılabilir.
- Emotion-to-Art Engine özgün sanat eserleri üretebilmektedir.

- Modüler ve genişletilebilir mimariye sahiptir.

Zayıf Yönler

- Modeller yalnızca DEAM veri seti üzerinde eğitilmiştir.
- Transformer modelleri veri miktarından etkilenmektedir.
- İnsan duygu algısı öznel olduğu için tam doğruluk mümkün değildir.
- Gemini çıktıları zaman zaman tutarsızlık gösterebilmektedir.
- Görsel üretim kalitesi kullanılan üretken modelin kapasitesine bağlıdır.

Genel Değerlendirme

Elde edilen sonuçlar, derin öğrenme tabanlı müzik duygu analizi modellerinin insan duygu algısına belirli ölçüde yaklaşabildiğini göstermektedir. Ensemble yaklaşımı tekil modellerden daha başarılı sonuçlar üretmiştir. Ayrıca multimodal yapay zeka sistemleri ve Emotion-to-Art Engine yapısının müzik duygu analizi çalışmalarına yeni bir bakış açısı kazandırdığı görülmüştür.

Bu bulgular, müzik duygu analizi ile üretken yapay zeka teknolojilerinin birlikte kullanılabileceğini ve gelecekte daha kapsamlı sistemlerin geliştirilebileceğini göstermektedir.

8. SONUÇ VE GELECEK ÇALIŞMALAR

Bu tez çalışmasında müzik duygu analizi problemi derin öğrenme, multimodal yapay zeka ve üretken yapay zeka teknolojileri kullanılarak incelenmiştir. Çalışma kapsamında DEAM veri seti üzerinde farklı derin öğrenme mimarileri geliştirilmiş, insan katılımcılardan elde edilen duygu değerlendirmeleri analiz edilmiş ve elde edilen sonuçlar Google Gemini 2.5 Flash modeli ile karşılaştırılmıştır. Ayrıca geliştirilen Emotion-to-Art Engine sistemi sayesinde müziklerden elde edilen duygu profilleri görsel sanat eserlerine dönüştürülmüştür.

Çalışmanın başlangıcında belirlenen temel hedefler; müziklerden Valence ve Arousal değerlerinin tahmin edilmesi, farklı yapay zeka modellerinin performanslarının karşılaştırılması, insan duygu algısı ile yapay zekâ çıktılarının değerlendirilmesi ve duygu analiz sonuçlarının görsel sanat üretiminde kullanılması olarak belirlenmiştir. Gerçekleştirilen deneyler sonucunda bu hedeflerin büyük ölçüde başarıyla gerçekleştirildiği görülmüştür.

Model geliştirme sürecinde CNN, CRNN, Transformer ve hibrit mimariler değerlendirilmiştir. Yapılan testler sonucunda CNN tabanlı modellerin genel olarak en dengeli performansı sergilediği, CRNN modellerinin ise zamansal ilişkileri

modelleme konusunda güçlü sonuçlar ürettiği gözlemlenmiştir. Transformer tabanlı modeller beklenen başarı seviyesine ulaşamamış olsa da farklı mimarilerin müzik duygu analizi üzerindeki etkileri karşılaştırmalı olarak incelenebilmiştir. Ayrıca geliştirilen ensemble yaklaşımı, farklı modellerin güçlü yönlerini birleştirerek tekil modellerden daha başarılı sonuçlar elde edilmesini sağlamıştır.

İnsan katılımcılardan elde edilen duygu verileri ile yapay zeka modellerinin çıktılarının karşılaştırılması, müzik duygu analizinin yalnızca akustik özelliklerden ibaret olmadığını göstermiştir. İnsanların müzik algısında kişisel deneyimler, kültürel faktörler ve bireysel farklılıklar da önemli rol oynamaktadır. Buna rağmen geliştirilen modellerin genel duygu eğilimlerini başarılı şekilde yakalayabildiği görülmüştür.

Çalışmanın önemli katkılarından biri de Google Gemini 2.5 Flash modelinin müzik duygu analizi sürecine dahil edilmesidir. Elde edilen sonuçlar, multimodal büyük dil modellerinin müzik duygu analizinde kullanılabileceğini göstermiştir. Bununla birlikte bazı durumlarda insan değerlendirmeleri ile model tahminleri arasında farklılıklar olduğu gözlemlenmiştir. Bu durum, multimodal yapay zeka sistemlerinin bu alandaki gelişim potansiyelini ortaya koymaktadır.

Çalışmanın güçlü yönlerinden biri olan Emotion-to-Art Engine sistemi sayesinde müziklerden elde edilen duygu verileri görsel sanat eserlerine dönüştürülmüştür. Sistemde kullanılan Emotion Profile, Art DNA, Color DNA ve Composition DNA bileşenleri sayesinde yalnızca duygu temelli değil, aynı zamanda özgün ve tekrarlanabilir sanat profilleri oluşturulabilmektedir. Bu yaklaşım müzik duygu analizi ile üretken yapay zekâ teknolojilerini bir araya getiren yenilikçi bir yapı sunmuştur.

Çalışmanın bazı sınırlılıkları da bulunmaktadır. Modeller yalnızca DEAM veri seti üzerinde eğitilmiş ve değerlendirilmiştir. Daha büyük ve farklı kültürleri temsil eden veri setlerinin kullanılması sonuçların genellenebilirliğini artırabilir. Ayrıca insan anketleri belirli bir katılımcı grubuyla gerçekleştirilmiştir. Daha geniş ve demografik açıdan daha çeşitli örneklerle yapılacak çalışmalar farklı sonuçlar ortaya koyabilir.

Gelecek çalışmalarda sistem çeşitli yönlerden geliştirilebilir. Öncelikle daha büyük müzik veri setleri kullanılarak Transformer tabanlı modellerin performansı yeniden değerlendirilebilir. Ses sinyaline ek olarak şarkı sözleri, albüm görselleri ve müzik videoları gibi farklı veri türlerinin sisteme dahil edilmesiyle daha kapsamlı multimodal analizler gerçekleştirilebilir. Bunun yanında gerçek zamanlı müzik analizi yapabilen sistemler geliştirilerek kullanıcıların dinledikleri müziğe anlık duygu analizi uygulanabilir.

Emotion-to-Art Engine tarafında ise kullanıcı tercihlerini dikkate alan kişiselleştirilmiş sanat üretim sistemleri geliştirilebilir. Ayrıca farklı üretken yapay zekâ modelleri kullanılarak görsel kalite artırılabilir ve üç boyutlu sanat üretimi gibi yeni uygulama alanları araştırılabilir.

Sonuç olarak bu çalışma, m zik duygu analizi, insan duygu algısı, multimodal yapay zekâ ve  retken sanat sistemlerini tek bir platform altında birleřtiren b t nleřik bir yaklařım sunmuřtur. Elde edilen bulgular, yapay zeka destekli m zik duygu analizi sistemlerinin gelecekte hem akademik arařtırmalarda hem de yaratıcı end strilerde  nemli kullanım alanlarına sahip olabileceđini g stermektedir.

 ZGE Mİř

Ecem Yal ın

2003 yılında İstanbul’da dođdu. İlk đrenimini İstanbul’da, ortaokul ve lise  đrenimini D zce’de tamamladı. 2022 yılında girdiđi Kocaeli M hendislik Fak ltesi Bilgisayar M hendisliđi B l m ’nden 2026 yılında Bilgisayar M hendisi olarak mezun olacak.

Beril  salar

2004 yılında İzmir’de dođdu. İlk ortaokul ve lise  đrenimini İzmir’de tamamladı. 2022 yılında girdiđi Kocaeli M hendislik Fak ltesi Bilgisayar M hendisliđi B l m ’nden 2026 yılında Bilgisayar M hendisi olarak mezun olacak.